

Kysymys 5: Mitä poikkeamilla tarkoitetaan? Anna esimerkki poikkeamien tunnistamisesta?

Mitä poikkeamilla tarkoitetaan

Poikkeamat ovat datan muista arvoista voimakkaasti poikkeavia arvoja, joiden mukaanottaminen dataan tehdessä päätelmiä voi vääristää saatua tulosta, eli tehtyjä päätelmiä.

Anna esimerkki poikkeamien tunnistamisesta

Poikkeamat voidaan havaita esim. keskiarvon ja keskihajonnan perusteella. Poikkeamiksi voidaan luokitella esimerkiksi numeerisen muuttujan arvot, jotka ovat yli kolmen keskihajonnan etäisyydellä keskiarvosta. Poikkeama-arvot on usein hyvä poistaa tarkasteltavasta datasta, sillä ne voivat vääristää tehtyjä päätelmiä. Myös jakauman persentiilejä käytetään poistettaessa poikkeusarvoja, esim. persentiilit 1-5 ja 96-100 voivat olla arvoryhmiä, jotka poistetaan tarkasteltavasta datasta.

Esimerkki Pycaretilla poikkeamien löytämisestä Valtiovarainministerin kuntadatasta:

Meillä on data

Queries [6] < = Table.RemoveColumns(#"Expanded Value",{ "Name" })

	ABC 123 Value.Kunta	ABC 123 Value.2019 Asukasluku	ABC 123 Value.2019 Kassan riittävyys. pv	ABC 123 Value.2019 Valtionosuudet
1	Akaa	16475	8.835897478	31449
2	Alajärvi	9562	10.2928284	34792
3	Alavieska	2519	34.64549212	8909
4	Alavus	11468	54.93049784	38072
5	Asikkala	8083	6.70478228	18410
6	Askola	4943	61.51845054	8303
7	Aura	3941	14.53952978	6002
8	Enonkoski	1361	93.26549697	5247
9	Enontekiö	1838	0.89304439	8789
10	Espoo	289731	140.1805034	60874
11	Eura	11632	8.463575707	24118
12	Eurajoki	9402	110.42774150000001	11120
13	Evijärvi	2425	115.857863	8860
14	Forssa	16901	61.88381764	40832
15	Haapajärvi	7010	89.96839071	23313
16	Haapavesi	6758	44.61634886	24589
17	Hailuoto	959	24.16067594	3426
18	Halsua	1127	15.29360791	4149
19	Hamina	20111	7.468003475	38153
20	Hankasalmi	4875	9.72675067	18486
21	Hanko	8199	10.77802949	12613
22	Harjavalta	6931	4.759259567	10331
23	Hartola	2697	17.4110538	8632
24	Hattula	9422	3.150089071	9721
25	Hausjärvi	8260	17.03516576	13454
26	Heinola	18667	194.8512144	43449
27	Heinävesi	3254	71.22490907	13570
28	Helsinki	653835	76.67420035	232776
29	Hirvensalmi	2136	246.02815959999998	6866
30	Hollola	23410	22.91745855	37747
31	Honkajoki	1620	26.26689887	4896

Dataan ajetaan python komennolla Pycaretin algoritmi, jolla havaitaan poikkeavuusarvot

Run Python script

Enter Python scripts into the editor to transform and shape your data.

Script

```
# 'dataset' holds the input data for this script
from pycaret.anomaly import *
dataset = get_outliers(data = dataset)
```

Saadaan poikkeavuudet (Value.Label: 1)

ABC 123	Value.Label	ABC 123	Value.Score
	0		1.526828912472595
	0		1.478188070733323
	0		1.4457235904884647
	0		1.5600543918005854
	0		1.4583847435674424
	0		1.4733192274995333
	0		1.446473071596348
	0		1.461546750397106
	0		1.4458413993875974
	1		9.743164880380265
	0		1.4526580203456898
	1		2.656658141588135
	0		1.53742471832373
	0		1.5838791817805375
	0		1.6262829057552743
	0		1.4601449152692278
	0		1.4434200439939473

Voidaan tarkastella poikkeamia osittamalla Value.Label = 1 arvon perusteella, jolloin voidaan havaita, mitkä kunnat ovat poikkeamia datassa

	ABC 123 Value.Kunta	ABC 123 Value.Label	ABC 123 Value.2019 Asukasluku	AI 1
1	Espoo	1	289731	1
2	Eurajoki	1	9402	1
3	Heinola	1	18667	1
4	Helsinki	1	653835	7
5	Hirvensalmi	1	2136	2
6	Jyväskylä	1	142400	0
7	Kajaani	1	36709	2
8	Kauniainen	1	9797	2
9	Kuopio	1	119282	1
10	Lahti	1	119823	1
11	Oulu	1	205489	3
12	Sotkamo	1	10336	3
13	Tampere	1	238140	3
14	Turku	1	192962	5
15	Vantaa	1	233775	2